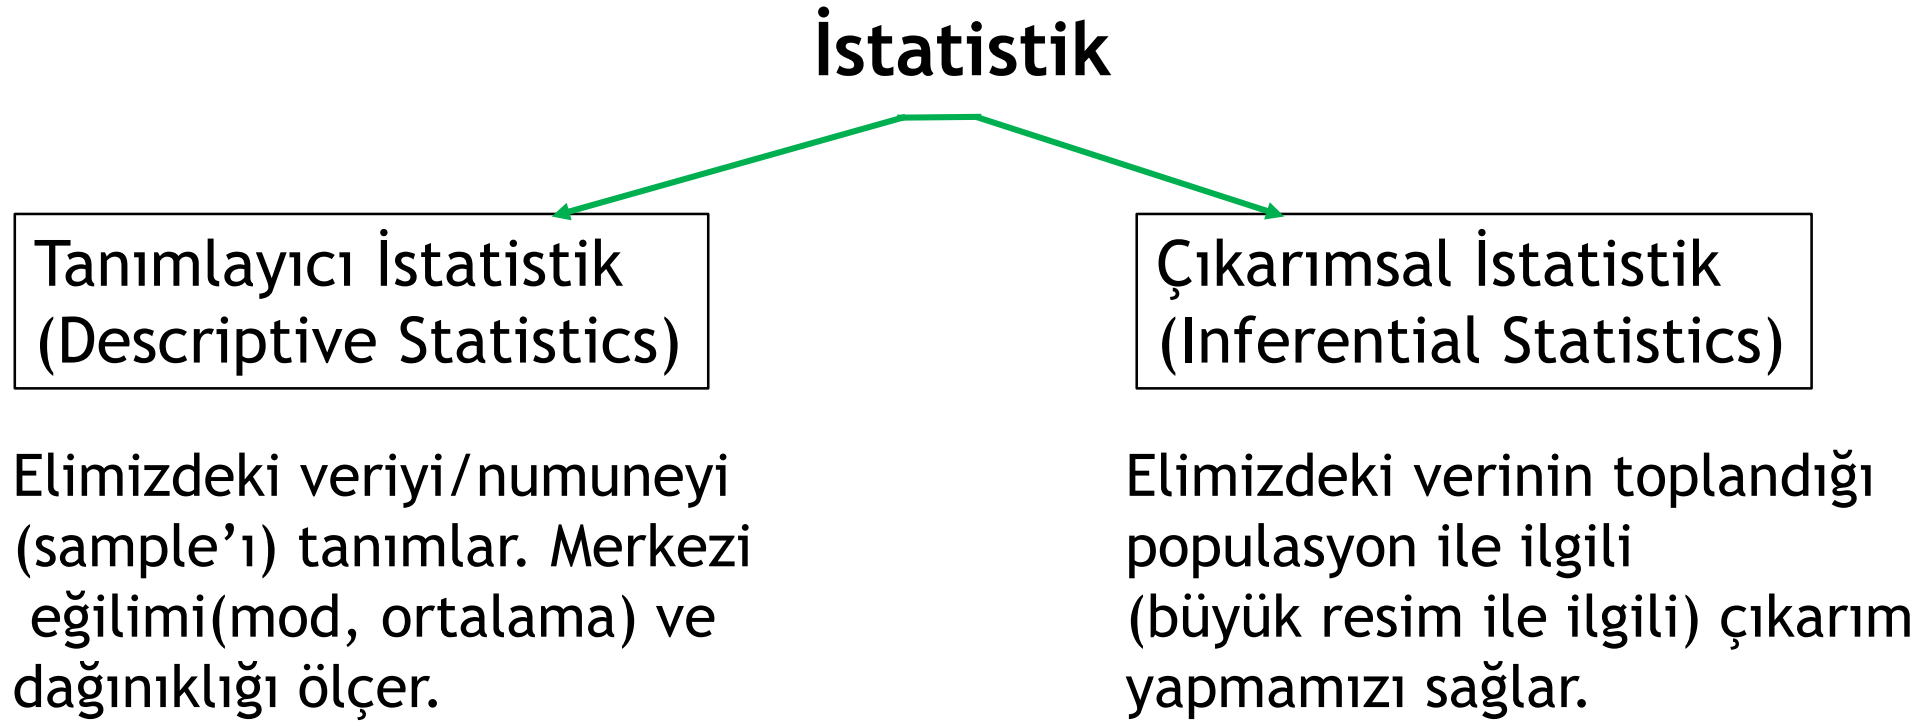


Olasılık ve İstatistik

Fırat İsmailoğlu, PhD

Merkezi Limit Teoremi

Daha önce istatistiği iki başlık altında toplamıştık: Tanımlayıcı İstatistik ve Çıkarımsal İstatistik:



Bu haftaya kadar tanımlayıcı istatistik ile ilgilendik. Elimizdeki veriyi anlamaya çalıştık. Şimdi ise çıkarımsal istatistik ile ilgileneceğiz. Verinin toplandığı populasyon hakkında bir çıkarım yapmaya çalışacağız.



Merkezi Limit Teoremi (Central Limit Theorem)


Populasyonun her bir bireyine bir sayı eşleyelim. Bu sayı örneğin bir kişinin boyu, kilosu, vucut sıcaklığı; yada bir fabrikada üretilen bir malın raf ömrü olabilir. Bu sayıları X_i rastgele değişkeni ile gösterelim (i . bireyin sayısal değeri). Bu rastgele değişkenlerin ortalaması μ ve standart sapması σ olsun. (Bunlar populasyonun parametreleri).

Bu populyasyondan aynı büyüklükte k tane rastgele örnekler (sample'lar) alalım. Örneğin bu büyüklük n olsun. Bu örneklerin ortalamalarını \bar{X}_i ile gösterelim (\bar{X}_i , i . örneğin ortalaması).

- Örneklerin ortalamaları $\bar{X}_1, \bar{X}_2, \dots, \bar{X}_k$ 'da bir rastgele değişkendir ve normal dağılıma sahip olur.
- Ortalamaların beklenen değeri populasyonun ortalaması μ 'ye eşit olur: $E[\bar{X}] = \mu$.
- Ortalamaların standart sapması populasyonun standart sapmasının \sqrt{n} 'e bölünmesiyle elde edilir: $\frac{\sigma}{\sqrt{n}}$



Merkezi Limit Teoremi (Central Limit Theorem)



ör. 30 yaşındaki erkeklerin büyük tansiyonlarının ortalaması 120, standart sapması 10 olsun. Bu durumda rastgele seçilen 9 kişilik bir grubun büyük tansiyonlarının ortalamasının 130'dan fazla olma olasılığı nedir?

Çözüm.

30 yaşındaki tüm erkeklerin kümesi popülasyonumuz olur. Bu popülasyondaki kişilerin büyük tansiyonlarının ortalaması $\mu = 120$ ve standart sapması $\sigma = 10$ olarak verilmiş.

\bar{X} rastgele değişkeni, 30 yaşındaki erkeklerden oluşan 9 kişilik herhangi bir grubun büyük tansiyonlarının ortalaması olsun. Biz $P(\bar{X} > 130)$ olasılığı ile ilgileniyoruz.

Merkezi limit teoremi gereği \bar{X} rastgele değişkenleri normal dağılıma sahiptir.

$$P(\bar{X} > 130) = P\left(Z > \frac{130 - 120}{\frac{10}{\sqrt{36}}}\right) = P(Z > 3) = 1 - P(\leq 3) = 1 - 0.9987 = 0.0013$$



ör. Bir fabrikada çalışan işçilerin kolestrol seviyelerinin ortalaması 202, standart sapması 14 olsun.

- i) İşçilerden 36 kişilik bir grup oluşturulduğunda, bu grubun kolestrol seviyelerinin 198 ile 206 arasında olma olasılığı nedir?
- ii) İşçilerden 64 kişilik bir grup oluşturulduğunda bu grubun kolestrol seviyelerinin yine 198 ile 206 arasında olma olasılığı nedir?

Çözüm.

- i) 36 kişilik grupların kolestrol seviyelerinin ortalamasını gösteren \bar{X} rastgele değişkeni merkezi limit teoremi gereği normal dağılıma sahip olur. O halde

$$\begin{aligned} P(198 \leq \bar{X} \leq 206) &= P\left(\frac{198 - 202}{14/\sqrt{36}} \leq Z \leq \frac{206 - 202}{14/\sqrt{36}}\right) = P(-1.714 \leq Z \leq 1.714) \\ &= P(Z \leq 1.714) - P(Z \leq -1.714) = 0.9564 - 0.0436 = 0.9128 \end{aligned}$$


- ii) $P(198 \leq \bar{X} \leq 206) = P\left(\frac{198-202}{14/\sqrt{64}} \leq Z \leq \frac{206-202}{14/\sqrt{64}}\right) = P(-2.286 \leq Z \leq 2.286) = 0.995$

Sonuç olarak grubun büyüklüğü artırıldığında grubun ortalaması populasyon ortalamasına yaklaşır.



Örneklerin büyüklükleri arttıkça (n arttıkça) örneklerin ortalamaları, populasyon ortalaması olan μ 'ye daha çok yaklaşır; ve örnek ortalamalarının standart sapması azalır, yani örneklerin ortalamaları birbirine daha çok benzer ve μ etrafında toplanır.

Bunun bir uygulaması olarak, her bir örnek (sample) bir zarın 50 defa atılmasının sonuçlarını içersin. Böylece her örnekte 50 eleman olur ve bunlar 1 – 6 arası değerlerdir. Bu şekilde 100 tane örnek oluşturalım. Yani 100 tane 50 büyüğünde örnek var olsun.



100 adet içinde 50 tane
1 – 6 arası sayı olan bu şekilde
örnek var.

Bu örnekleri R programlama dilinde yada başka bir dilde kolayca oluşturabiliriz. R'de her bir örnek için:

```
>>sample(1:6,50, replace=True)
```

Bu örneklerin ortalamasını basitçe `mean` komutuyla alabiliriz:

```
>>mean(sample(1:6,50, replace=True))
```

Üretilen her örneğin ortalamasını, bir arrayde tutalım:


```
>>kucukArray=c(1:100) # once arrayi tanımlayalım.
```

```
>> for (i in 1:100){
```


```
kucukArray[i]=mean(sample(1:6,50, replace=T)) }
```

Bu array'in histogramını çizerek 50'lik örneklerde ortalamanın daha çok hangi değerler aldığını görelim

```
>>hist(kucukArray,xlim=c(1,6))
```



Şimdi de herbir örnek (sample) bir zarın 1000 defa atılmasının sonuçlarını içersin. Böylece her örnekte 1000 eleman olur ve bunlar 1 – 6 arası değerlerdir. Bu şekilde 1000 tane örnek oluşturalım.



100 tane içinde 1000 tane
1 – 6 arası sayı olan bu
şekilde örnek var.

Bu örnekleri R'de

```
>> sample(1:6, 1000, replace=True)
```

kodu ile oluşturabiliriz.

Oluşan örneklerin ortalamasını bir arrayde tutalım:


```
>> buyukArray=c(1:100)
```



```
>> for (i in 1:100) {  
buyukArray[i]=mean(sample(1:6,1000, replace=T)) }
```

Bu array'in histogramını çizerek 1000'lik örneklerde ortalamanın daha çok hangi değerler aldığını görelim:

```
>>hist(buyukArray,xlim=c(1,6))
```



1000 elemana sahip örneklerin ortalamaları, 50 elemana sahip örneklerin ortalamalarına göre gerçek populasyon ortalaması olan 3.5 değerine çok daha yakın ve bu ortalamaların birbirinden uzaklığı (sapmaları) daha az.

```
>> for (i in 1:100) {
```

```
  buyukArray[i]=mean(sample(1:6,1000, replace=T)) }
```

Bu array'in histogramını çizerek 1000'lik örneklerde ortalamanın daha çok hangi değerler aldığını görelim:

```
>>hist(buyukArray,xlim=c(1,6))
```

ör. Pil üreten bir fabrikanın ürettiği pillerin ömrünün ortalaması μ , standart sapması 100 olsun. Rastgele 10 pil alındığında bu pillerin ömürlerinin ortalamalarının μ 'den 20 fazla olma olasılığı ne olur?

Çözüm.

\bar{X} rastgele değişkeni 10 büyüklüğündeki pil gruplarının ortalama ömrü olsun. Merkezi limit teoremi gereği \bar{X} normal dağılıma sahiptir.

$$P(\bar{X} \geq \mu + 20) = P\left(Z \geq \frac{\mu + 20 - \mu}{\frac{100}{\sqrt{10}}}\right) = P(Z \geq 0.63) = 1 - P(Z < 0.63)$$

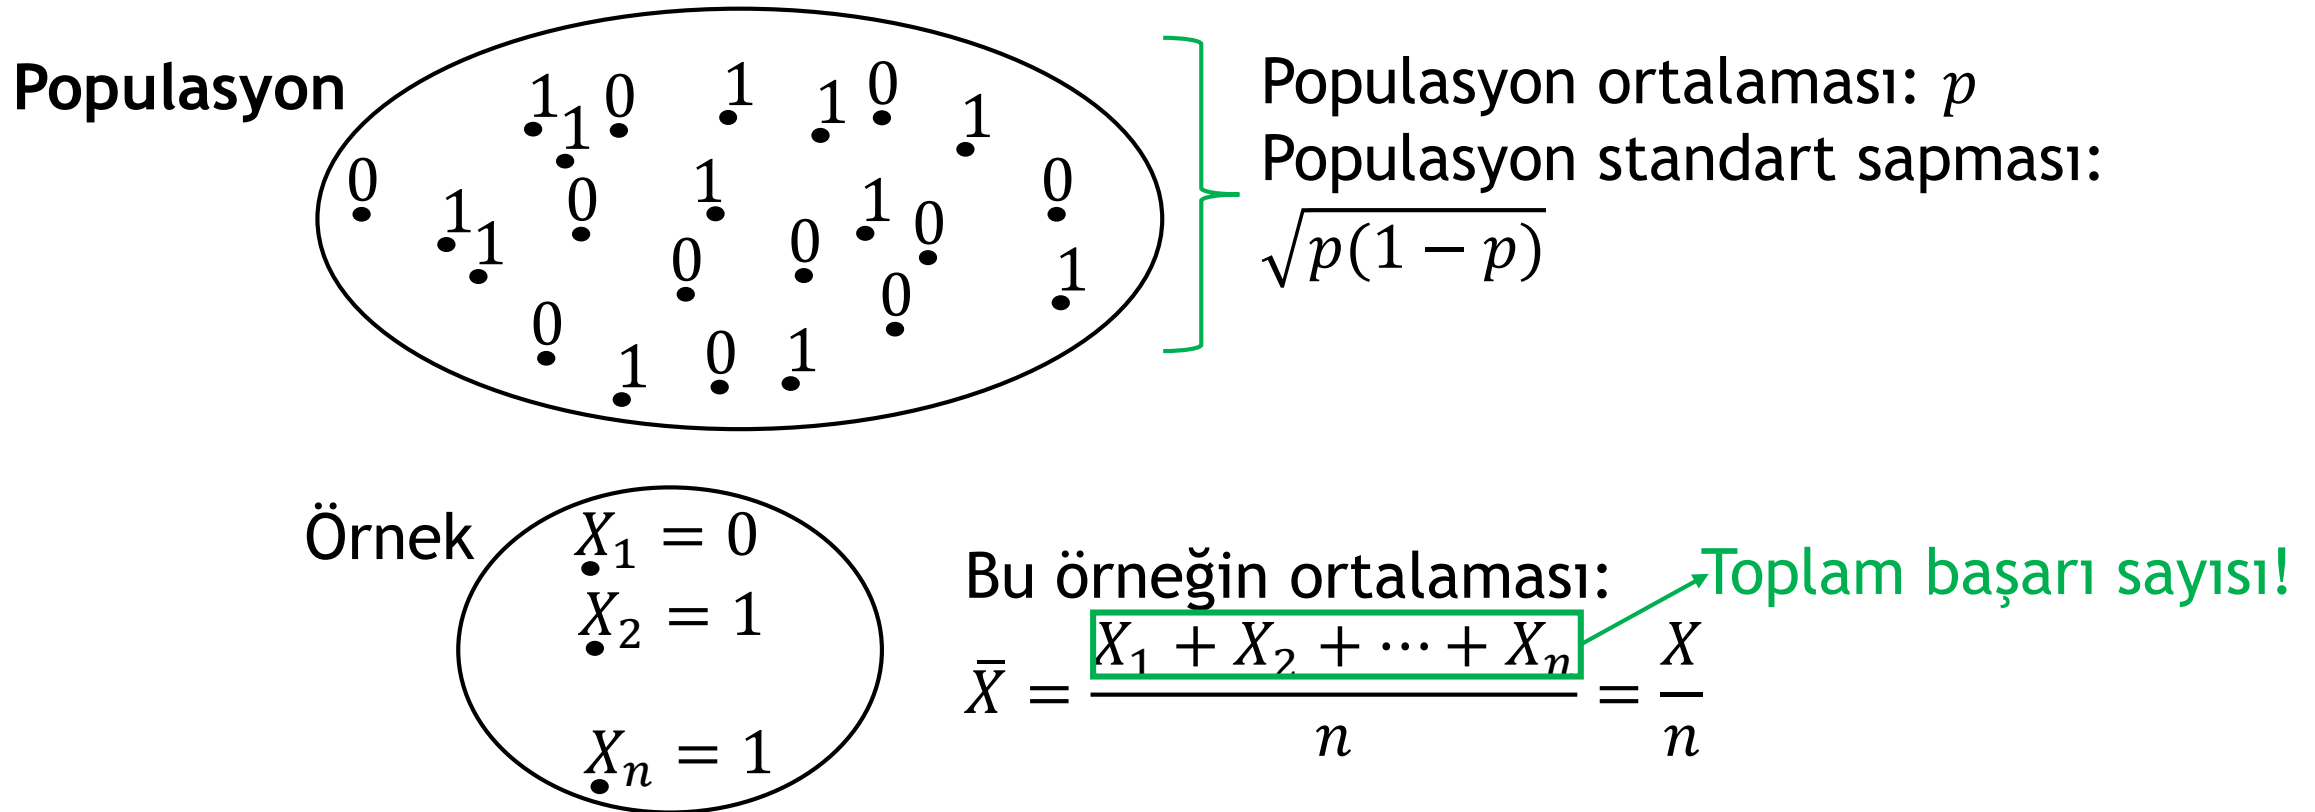
$$= 1 - 0.7357$$

$$= 0.2643$$



Merkezi Limit Teoremi Yardımıyla Normal Dağılım Kullanarak Binomial Dağılıma Yaklaşmak

Bernoulli rastgele değişkenlerinden oluşan bir popülasyonumuz olsun. (Yani popülasyonda yalnızca 0 (başarısızlık) ve 1 (başarı) değerleri var. Buradan n elemana sahip bir örnek alalım.



Merkezi limit teoremi gereği $\bar{X} = \frac{X}{n}$ normal dağılıma sahip olur. Bunu standart

normal dağılımdaki karşılığı:
$$Z = \frac{\frac{X}{n} - p}{\frac{\sqrt{p(1-p)}}{\sqrt{n}}} = \frac{\frac{X - np}{n}}{\sqrt{\frac{p(1-p)}{n}}} = \frac{X - np}{\sqrt{np(1-p)}}$$

$\frac{X - np}{\sqrt{np(1-p)}}$ yaklaşık olarak normal dağılıma sahip olur. Burada X , toplam başarı sayısını gösterdiğinden binomial rastgele değişken olur.


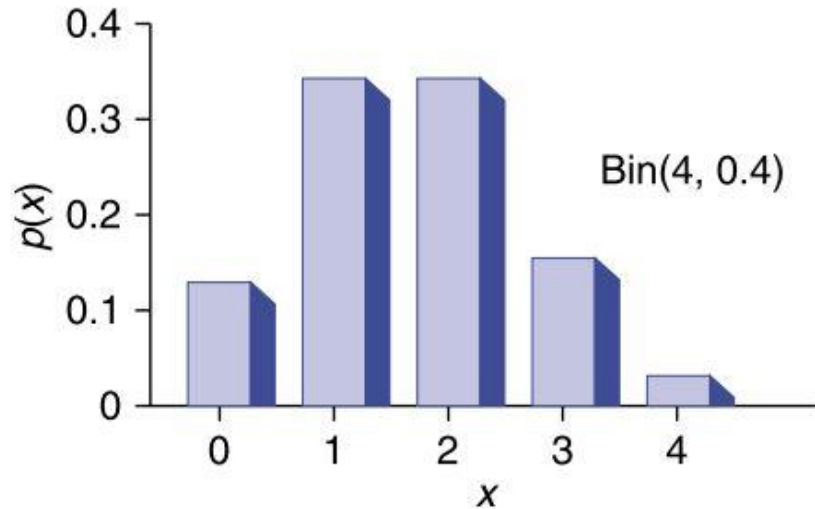
ör. Varsayalımki bir popülasyonun %46'sı bir A adayını desteklesin. Bu popülasyondan rastgele seçeceğimiz 200 kişinin en az 100'ünün A adayını destekleme olasılığı nedir?

Çözüm.


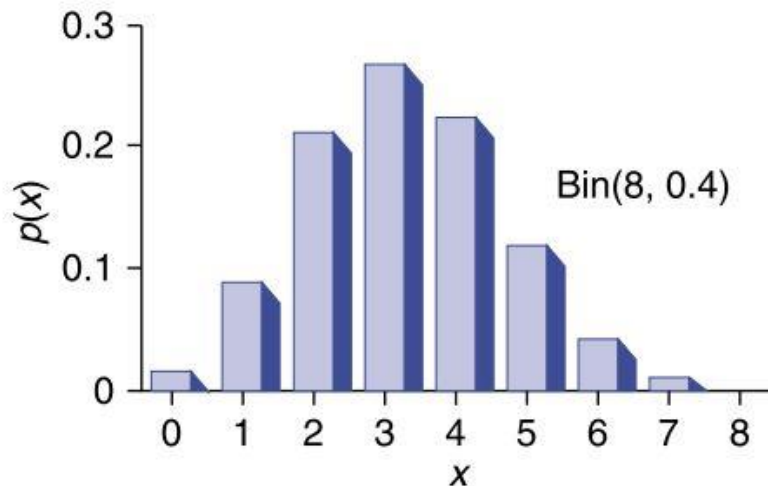
X rastgele değişkeni seçilen 200 kişiden A'yı destekleyen toplam kişi sayısını gösterebilir. Biz $P(X \geq 100)$ ile ilgileniyoruz.



$$P(X \geq 100) = P\left(Z \geq \frac{100 - 200 \times 0.46}{\sqrt{200 \times 0.46(1 - 0.46)}}\right) = P(Z \geq 1.135) = 1 - P(Z < 1.135) \\ = 0.0885$$



n (yani deney tekrar sayısı) arttıkça binomial dağılım , normal dağılıma benzer.



ör. Bir fabrikanın ürettiği malların %10'u bozuk olsun. Bu fabrikanın ürettiği mallardan rastgele seçilen 8 malın,

- i) hiçbirinin
 - ii) %15'inden fazlasının
- bozuk olma olasılığı nedir?

Çözüm.

X rastgele değişkeni bu fabrikanın ürettiği mallardan rastgele seçilen 8 maldaki toplam bozuk sayısı olsun.

$p = 0.1$ başarı oranı

i) $P(X = 0) = (1 - 0.1)^8 = 0.43$

ii)
$$P\left(X > 8 \times \frac{15}{100}\right) = P(X > 1.2) = P\left(Z > \frac{1.2 - 8 \times 0.1}{\sqrt{8 \times 0.1 \times (0.9)}}\right) = P(Z > 0.471) =$$
$$= 1 - P(Z \leq 0.471) = 1 - 0.68 = 0.32$$

